nerc

March 21, 2023

0.0.1 Import Libraries

[1]:
```
from collections import Counter
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
import sklearn
from sklearn.metrics import classification_report, confusion_matrix
```

0.0.2 Import Dataset

[2]:
```
from google.colab import drive
drive.mount('/content/drive')
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call
drive.mount("/content/drive", force_remount=True).
```

[3]:
```
data_path = "/content/drive/MyDrive/text mining group/dataset/NERC_dataset/
 ↪ner_dataset.csv"
```

[4]:
```
data = pd.read_csv(data_path, encoding="latin1")
```

[5]:
```
data.count()
```

[5]:
```
Sentence #      47959
Word          1048575
POS           1048575
Tag           1048575
dtype: int64
```

[6]:
```
data[100:300]
```

[6]:

	Sentence #	Word	POS	Tag
100	NaN	the	DT	O
101	NaN	southern	JJ	O
102	NaN	English	JJ	B-gpe
103	NaN	seaside	NN	O

```
104           NaN    resort   NN      O
..            …       …  …    …
295           NaN         .    .      O
296  Sentence: 14       Two   CD      O
297           NaN   Germans  NNS  B-gpe
298           NaN       and   CC      O
299           NaN      four   CD      O

[200 rows x 4 columns]
```

[7]:
```
len(data)
```

[7]:
```
1048575
```

[8]:
```
df_train = data[:100000]
```

[9]:
```
training_features = []
training_gold_labels = []

for index, instance in df_train.iterrows():
    a_dict = {
        'words': instance['Word'],
        #'pos': instance['POS']
    }
    training_features.append(a_dict)
    training_gold_labels.append(instance['Tag'].upper())
```

[10]:
```
test_data = pd.read_table(r"/content/drive/MyDrive/text mining group/test/
 ↪NER-final-test.tsv", encoding="latin1")
```

[11]:
```
test_data
```

[11]:
```
     sentence id  token id  token BIO NER tag
0              0         0     It           O
1              0         1   took           O
2              0         2  eight           O
3              0         3  years           O
4              0         4    for           O
..           …       …    …         …
209            9        12    get           O
210            9        13   into           O
211            9        14   this           O
212            9        15    one           O
213            9        16      .           O

[214 rows x 4 columns]
```

[12]:
```
df_test = test_data
```

[13]:
```
test_features = []
test_gold_labels = []

for index, instance in df_test.iterrows():
    a_dict = {
        'words': instance['token'],
        #'pos': instance['POS']
    }
    test_features.append(a_dict)
    test_gold_labels.append(instance['BIO NER tag'])
```

[14]:
```
len(training_gold_labels)
```

[14]: 100000

[15]:
```
len(test_gold_labels)
```

[15]: 214

[16]:
```
training_gold_labels
```

[16]:
```
['O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'B-GEO',
 'O',
 'O',
 'O',
 'O',
 'O',
 'B-GEO',
 'O',
 'O',
 'O',
 'O',
 'O',
 'B-GPE',
 'O',
 'O',
 'O',
 'O',
 'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-PER',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'I-GEO',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'B-ORG',
'I-ORG',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
```

```
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'B-GEO',
'O',
'O',
'B-GEO',
'O',
'O',
'B-ORG',
'I-ORG',
'I-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'B-GEO',
'B-TIM',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-TIM',
```

```
'O',
'O',
'O',
'B-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'I-ORG',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'B-ORG',
'I-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'B-GPE',
'O',
'O',
'O',
'B-ART',
'I-ART',
'O',
'O',
'B-GPE',
'O',
'O',
'B-PER',
'I-PER',
'I-PER',
'O',
'B-TIM',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'B-ORG',
'I-ORG',
'O',
'B-PER',
'I-PER',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-TIM',
'O',
'O',
'O',
'O',
'B-GEO',
'I-GEO',
'O',
'B-GEO',
'I-GEO',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'I-ORG',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'I-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'B-PER',
'I-PER',
'I-PER',
'I-PER',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'B-TIM',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
```

```
'O',
'O',
'B-ORG',
'I-ORG',
'I-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'I-GEO',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'I-ORG',
'I-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'B-TIM',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-TIM',
'O',
'O',
```

```
'O',
'O',
'B-TIM',
'O',
'B-GEO',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-TIM',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-GEO',
'O',
'B-GEO',
'I-GEO',
'I-GEO',
'I-GEO',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-TIM',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-TIM',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'O',
'O',
'B-GEO',
'O',
'B-GPE',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
```

```
 'O',
 'B-PER',
 'I-PER',
 'O',
 'B-GPE',
 'O',
 'O',
 'B-TIM',
 'O',
 'B-PER',
 'I-PER',
 'O',
 'O',
 'O',
 'B-GEO',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'B-ORG',
 'I-ORG',
 'I-ORG',
 'O',
 'O',
 'O',
 'O',
 'B-PER',
 'O',
 'O',
 …]
```

[17]:
```
test_gold_labels
```

[17]:
```
['O',
 'O',
 'O',
 'O',
 'O',
 'B-ORG',
 'I-ORG',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'I-ORG',
'I-ORG',
'O',
'O',
'O',
'O',
'O',
'B-LOC',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-MISC',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-PER',
'I-PER',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-PER',
'I-PER',
'O',
'O',
'B-PER',
'I-PER',
'I-PER',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'B-MISC',
'I-MISC',
'O',
'O',
'O',
'O',
'O',
'B-ORG',
'O',
'B-PER',
'I-PER',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-LOC',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
```

```
'O',
'O',
'O',
'B-ORG',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-PER',
'I-PER',
'I-PER',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-PER',
'I-PER',
'O',
'O',
'O',
'B-LOC',
'I-LOC',
'O',
'O',
'O',
'O',
'O',
'O',
'O',
'B-LOC',
```

```
 'I-LOC',
 'O',
 'O',
 'O',
 'O',
 'O',
 'B-MISC',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O',
 'O']
```

[18]:
```
print(training_features[:1])
print(training_gold_labels[:1])
print(test_features)
print(test_gold_labels)
```

```
[{'words': 'Thousands'}]
['O']
[{'words': 'It'}, {'words': 'took'}, {'words': 'eight'}, {'words': 'years'},
{'words': 'for'}, {'words': 'Warner'}, {'words': 'Brothers'}, {'words': 'to'},
{'words': 'recover'}, {'words': 'from'}, {'words': 'the'}, {'words':
'disaster'}, {'words': 'that'}, {'words': 'was'}, {'words': 'this'}, {'words':
'movie'}, {'words': '.'}, {'words': 'All'}, {'words': 'the'}, {'words': 'New'},
{'words': 'York'}, {'words': 'University'}, {'words': 'students'}, {'words':
'love'}, {'words': 'this'}, {'words': 'diner'}, {'words': 'in'}, {'words':
'Soho'}, {'words': 'so'}, {'words': 'it'}, {'words': 'makes'}, {'words': 'for'},
{'words': 'a'}, {'words': 'fun'}, {'words': 'young'}, {'words': 'atmosphere'},
{'words': '.'}, {'words': 'This'}, {'words': 'Italian'}, {'words': 'place'},
{'words': 'is'}, {'words': 'really'}, {'words': 'trendy'}, {'words': 'but'},
{'words': 'they'}, {'words': 'have'}, {'words': 'forgotten'}, {'words':
'about'}, {'words': 'the'}, {'words': 'most'}, {'words': 'important'}, {'words':
'part'}, {'words': 'of'}, {'words': 'a'}, {'words': 'restaurant'}, {'words':
','}, {'words': 'the'}, {'words': 'food'}, {'words': '.'}, {'words': 'In'},
{'words': 'conclusion'}, {'words': ','}, {'words': 'my'}, {'words': 'review'},
{'words': 'of'}, {'words': 'this'}, {'words': 'book'}, {'words': 'would'},
{'words': 'be'}, {'words': ':'}, {'words': 'I'}, {'words': 'like'}, {'words':
'Jane'}, {'words': 'Austen'}, {'words': 'and'}, {'words': 'understand'},
{'words': 'why'}, {'words': 'she'}, {'words': 'is'}, {'words': 'famous'},
```

{'words': '.'}, {'words': 'The'}, {'words': 'story'}, {'words': 'of'}, {'words': 'this'}, {'words': 'movie'}, {'words': 'is'}, {'words': 'focused'}, {'words': 'on'}, {'words': 'Carl'}, {'words': 'Brashear'}, {'words': 'played'}, {'words': 'by'}, {'words': 'Cuba'}, {'words': 'Gooding'}, {'words': 'Jr.'}, {'words': 'who'}, {'words': 'wants'}, {'words': 'to'}, {'words': 'be'}, {'words': 'the'}, {'words': 'first'}, {'words': 'African'}, {'words': 'American'}, {'words': 'deep'}, {'words': 'sea'}, {'words': 'diver'}, {'words': 'in'}, {'words': 'the'}, {'words': 'Navy'}, {'words': '.'}, {'words': 'Chris'}, {'words': "O'Donnell"}, {'words': 'stated'}, {'words': 'that'}, {'words': 'while'}, {'words': 'filming'}, {'words': 'for'}, {'words': 'this'}, {'words': 'movie'}, {'words': ','}, {'words': 'he'}, {'words': 'felt'}, {'words': 'like'}, {'words': 'he'}, {'words': 'was'}, {'words': 'in'}, {'words': 'a'}, {'words': 'toy'}, {'words': 'commercial'}, {'words': '.'}, {'words': 'My'}, {'words': 'husband'}, {'words': 'and'}, {'words': 'I'}, {'words': 'moved'}, {'words': 'to'}, {'words': 'Amsterdam'}, {'words': '6'}, {'words': 'years'}, {'words': 'ago'}, {'words': 'and'}, {'words': 'for'}, {'words': 'as'}, {'words': 'long'}, {'words': 'as'}, {'words': 'we'}, {'words': 'have'}, {'words': 'lived'}, {'words': 'here'}, {'words': ','}, {'words': 'Blauwbrug'}, {'words': 'has'}, {'words': 'been'}, {'words': 'our'}, {'words': 'favorite'}, {'words': 'place'}, {'words': 'to'}, {'words': 'eat'}, {'words': '!'}, {'words': 'Dame'}, {'words': 'Maggie'}, {'words': 'Smith'}, {'words': 'performed'}, {'words': 'her'}, {'words': 'role'}, {'words': 'excellently'}, {'words': ','}, {'words': 'as'}, {'words': 'she'}, {'words': 'does'}, {'words': 'in'}, {'words': 'all'}, {'words': 'her'}, {'words': 'movies'}, {'words': '.'}, {'words': 'The'}, {'words': 'new'}, {'words': 'movie'}, {'words': 'by'}, {'words': 'Mr.'}, {'words': 'Kruno'}, {'words': 'was'}, {'words': 'shot'}, {'words': 'in'}, {'words': 'New'}, {'words': 'York'}, {'words': ','}, {'words': 'but'}, {'words': 'the'}, {'words': 'story'}, {'words': 'takes'}, {'words': 'place'}, {'words': 'in'}, {'words': 'Los'}, {'words': 'Angeles'}, {'words': '.'}, {'words': 'I'}, {'words': 'always'}, {'words': 'have'}, {'words': 'loved'}, {'words': 'English'}, {'words': 'novels'}, {'words': ','}, {'words': 'but'}, {'words': 'I'}, {'words': 'just'}, {'words': 'could'}, {'words': "n't"}, {'words': 'get'}, {'words': 'into'}, {'words': 'this'}, {'words': 'one'}, {'words': '.'}]
['O', 'O', 'O', 'O', 'O', 'B-ORG', 'I-ORG', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-ORG', 'I-ORG', 'I-ORG', 'O', 'O', 'O', 'O', 'O', 'B-LOC', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-MISC', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-PER', 'I-PER', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-PER', 'I-PER', 'O', 'O', 'B-PER', 'I-PER', 'I-PER', 'O', 'O', 'O', 'O', 'O', 'O', 'B-MISC', 'I-MISC', 'O', 'O', 'O', 'O', 'O', 'B-ORG', 'O', 'B-PER', 'I-PER', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-LOC', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-ORG', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-PER', 'I-PER', 'I-PER', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-PER', 'I-PER', 'O', 'O', 'O', 'B-LOC', 'I-LOC', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-LOC', 'I-LOC', 'O', 'O', 'O', 'O', 'O', 'B-MISC', 'O', 'O', 'O', 'O', 'O', 'O', 'O',

```
'O', 'O', 'O', 'O', 'O']
```

[19]:
```
num_instances_train = len(training_features)
num_instances_test = len(test_features)
```

[20]:
```
num_instances_train
```

[20]:
```
100000
```

[21]:
```
num_instances_test
```

[21]:
```
214
```

[22]:
```
frequency_label_train = Counter(training_gold_labels)
frequency_label_train
```

[22]:
```
Counter({'O': 84725,
         'B-GEO': 3303,
         'B-GPE': 1740,
         'B-PER': 1668,
         'I-GEO': 690,
         'B-ORG': 1876,
         'I-ORG': 1470,
         'B-TIM': 1823,
         'B-ART': 75,
         'I-ART': 43,
         'I-PER': 1846,
         'I-GPE': 51,
         'I-TIM': 549,
         'B-NAT': 30,
         'B-EVE': 53,
         'I-EVE': 47,
         'I-NAT': 11})
```

[23]:
```
plt.rcParams["figure.figsize"] = [15, 10]
plt.rcParams["figure.autolayout"] = True
plt.bar(frequency_label_train.keys(), frequency_label_train.values())
```

[23]:
```
<BarContainer object of 17 artists>
```

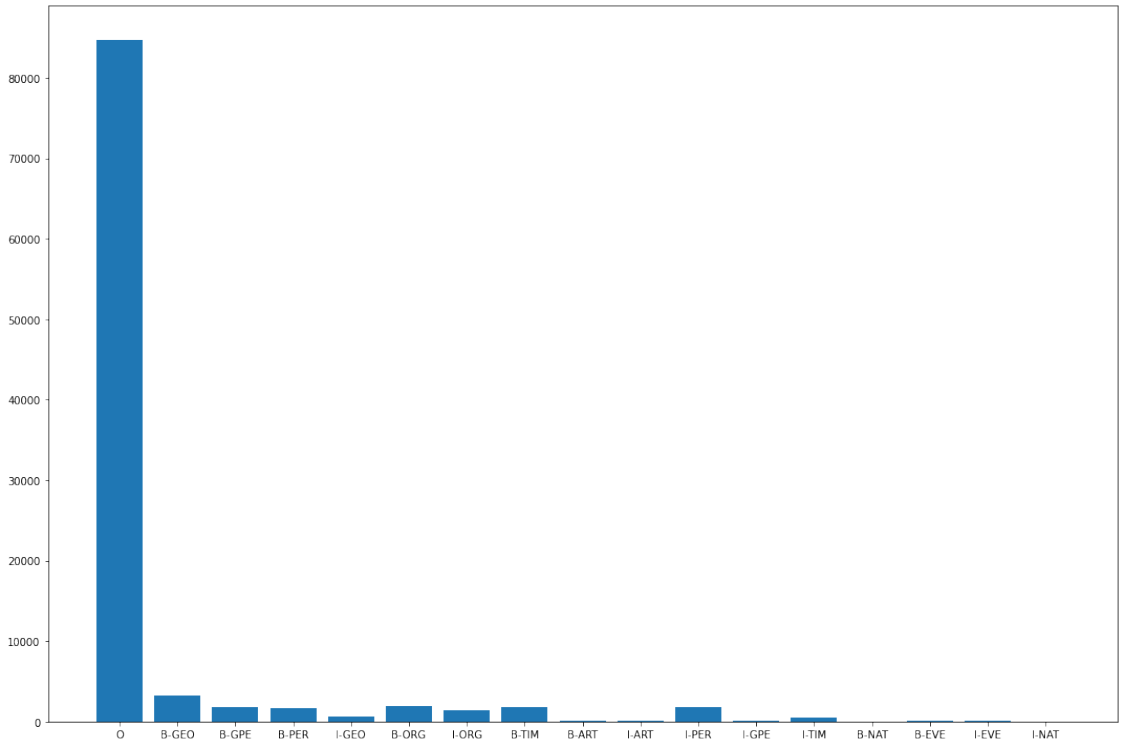

[24]:
```
frequency_label_test = Counter(test_gold_labels)
frequency_label_test
```

[24]:
```
Counter({'O': 183,
         'B-ORG': 4,
         'I-ORG': 3,
         'B-LOC': 4,
         'B-MISC': 3,
         'B-PER': 6,
         'I-PER': 8,
         'I-MISC': 1,
         'I-LOC': 2})
```

[25]:
```
plt.rcParams["figure.figsize"] = [15, 10]
plt.rcParams["figure.autolayout"] = True
plt.bar(frequency_label_test.keys(), frequency_label_test.values())
```

[25]:
```
<BarContainer object of 9 artists>
```

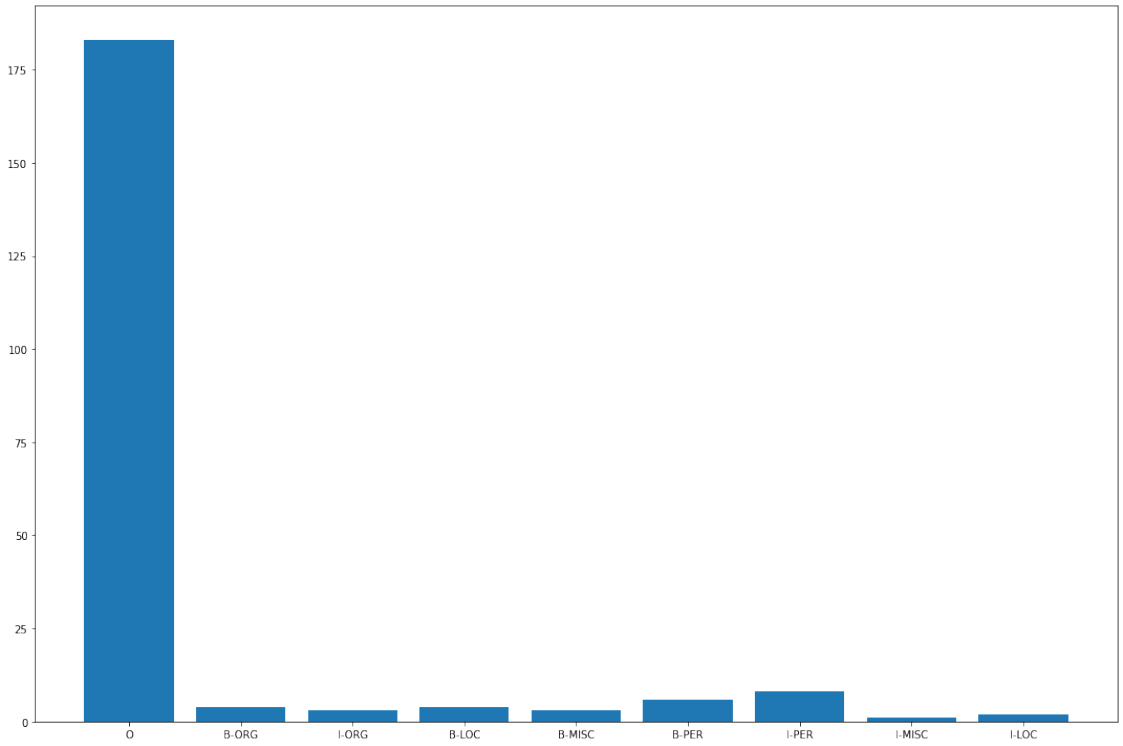

[26]:
```
all_features = training_features + test_features
```

[27]:
```
from sklearn.feature_extraction import DictVectorizer
```

[28]:
```
vec = DictVectorizer()
the_array = vec.fit_transform(all_features).toarray()
```

[29]:
```
training_onehot = the_array[:len(training_features)]
test_onehot = the_array[len(training_features):]
```

[30]:
```
print('Number of training words =', training_onehot.shape)
print('Number of test words =', test_onehot.shape)
```

```
Number of training words = (100000, 10955)
Number of test words = (214, 10955)
```

[31]:
```
training_onehot
```

[31]:
```
array([[0., 0., 0., …, 0., 0., 0.],
       [0., 0., 0., …, 0., 0., 0.],
       [0., 0., 0., …, 0., 0., 0.],
       …,
       [0., 0., 0., …, 0., 0., 0.],
```

```
       [0., 0., 0., …, 0., 0., 0.],
       [0., 0., 0., …, 0., 0., 0.]])
```

[32]:
```
test_onehot
```

[32]:
```
array([[0., 0., 0., …, 0., 0., 0.],
       [0., 0., 0., …, 0., 0., 0.],
       [0., 0., 0., …, 0., 0., 0.],
       …,
       [0., 0., 0., …, 0., 0., 0.],
       [0., 0., 0., …, 0., 0., 0.],
       [0., 0., 0., …, 0., 0., 0.]])
```

0.0.3 Training with SVM

[33]:
```
from sklearn import svm
```

[34]:
```
lin_clf = svm.LinearSVC()
```

[35]:
```
lin_clf.fit(training_onehot, training_gold_labels)
```

[35]:
```
LinearSVC()
```

[36]:
```
pred = lin_clf.predict(test_onehot)
print(pred)
```

```
['O' 'O' 'O' 'O' 'O' 'I-PER' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'B-GEO' 'I-GEO' 'I-ORG' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'O' 'O' 'O' 'O' 'B-GPE' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'B-GEO' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'B-GPE' 'B-GPE' 'O' 'O' 'O' 'O' 'O' 'B-ORG' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'O' 'I-TIM' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'I-PER' 'O' 'O' 'O' 'O' 'O' 'O'
 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'B-PER' 'O' 'O' 'O' 'O'
 'B-GEO' 'I-GEO' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'B-GEO' 'I-GEO' 'O' 'O' 'O'
 'O' 'O' 'B-GPE' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O' 'O']
```

[38]:
```
pred[:5]
```

[38]:
```
array(['O', 'O', 'O', 'O', 'O'], dtype='<U5')
```

0.0.4 Analysis

[39]:
```
from sklearn.metrics import classification_report
report = classification_report(test_gold_labels, pred)
```

```
/usr/local/lib/python3.9/dist-packages/sklearn/metrics/_classification.py:1344:
UndefinedMetricWarning: Precision and F-score are ill-defined and being set to
0.0 in labels with no predicted samples. Use `zero_division` parameter to
control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.9/dist-packages/sklearn/metrics/_classification.py:1344:
UndefinedMetricWarning: Recall and F-score are ill-defined and being set to 0.0
in labels with no true samples. Use `zero_division` parameter to control this
behavior.
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.9/dist-packages/sklearn/metrics/_classification.py:1344:
UndefinedMetricWarning: Precision and F-score are ill-defined and being set to
0.0 in labels with no predicted samples. Use `zero_division` parameter to
control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.9/dist-packages/sklearn/metrics/_classification.py:1344:
UndefinedMetricWarning: Recall and F-score are ill-defined and being set to 0.0
in labels with no true samples. Use `zero_division` parameter to control this
behavior.
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.9/dist-packages/sklearn/metrics/_classification.py:1344:
UndefinedMetricWarning: Precision and F-score are ill-defined and being set to
0.0 in labels with no predicted samples. Use `zero_division` parameter to
control this behavior.
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.9/dist-packages/sklearn/metrics/_classification.py:1344:
UndefinedMetricWarning: Recall and F-score are ill-defined and being set to 0.0
in labels with no true samples. Use `zero_division` parameter to control this
behavior.
  _warn_prf(average, modifier, msg_start, len(result))
```

[40]:
```
report
```

[40]:
```
'              precision    recall  f1-score   support\n\n       B-GEO
0.00      0.00      0.00         0\n       B-GPE       0.00      0.00      0.00
0\n      B-LOC       0.00      0.00      0.00         4\n      B-MISC
0.00      0.00      0.00         3\n       B-ORG       1.00      0.25      0.40
4\n      B-PER       1.00      0.17      0.29         6\n       I-GEO
0.00      0.00      0.00         0\n       I-LOC       0.00      0.00      0.00
2\n     I-MISC       0.00      0.00      0.00         1\n       I-ORG
1.00      0.33      0.50         3\n       I-PER       0.50      0.12      0.20
8\n      I-TIM       0.00      0.00      0.00         0\n           O
0.92      0.99      0.96       183\n\n    accuracy
```

```
0.87       214\n   macro avg       0.34      0.14      0.18       214\nweighted
avg       0.87      0.87      0.85       214\n'
```

[41]:
```
cm = confusion_matrix(test_gold_labels,pred)
cm
```

[41]:
```
array([[  0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0],
       [  0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0],
       [  2,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   2],
       [  0,   3,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0],
       [  1,   0,   0,   0,   1,   0,   0,   0,   0,   0,   1,   0,   1],
       [  1,   0,   0,   0,   0,   1,   0,   0,   0,   0,   0,   0,   4],
       [  0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0],
       [  0,   0,   0,   0,   0,   0,   2,   0,   0,   0,   0,   0,   0],
       [  0,   1,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0],
       [  0,   0,   0,   0,   0,   0,   1,   0,   0,   1,   0,   0,   1],
       [  0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   1,   0,   7],
       [  0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0],
       [  0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   0,   1, 182]])
```

[42]:
```
plt.figure(figsize = (10,10))
sns.heatmap(cm,cmap= "Blues", linecolor = 'black' , linewidth = 1 , annot =␣
 ↪True, fmt='' )
plt.xlabel("Predicted")
plt.ylabel("Actual")
```

[42]:
```
Text(6.800000000000001, 0.5, 'Actual')
```

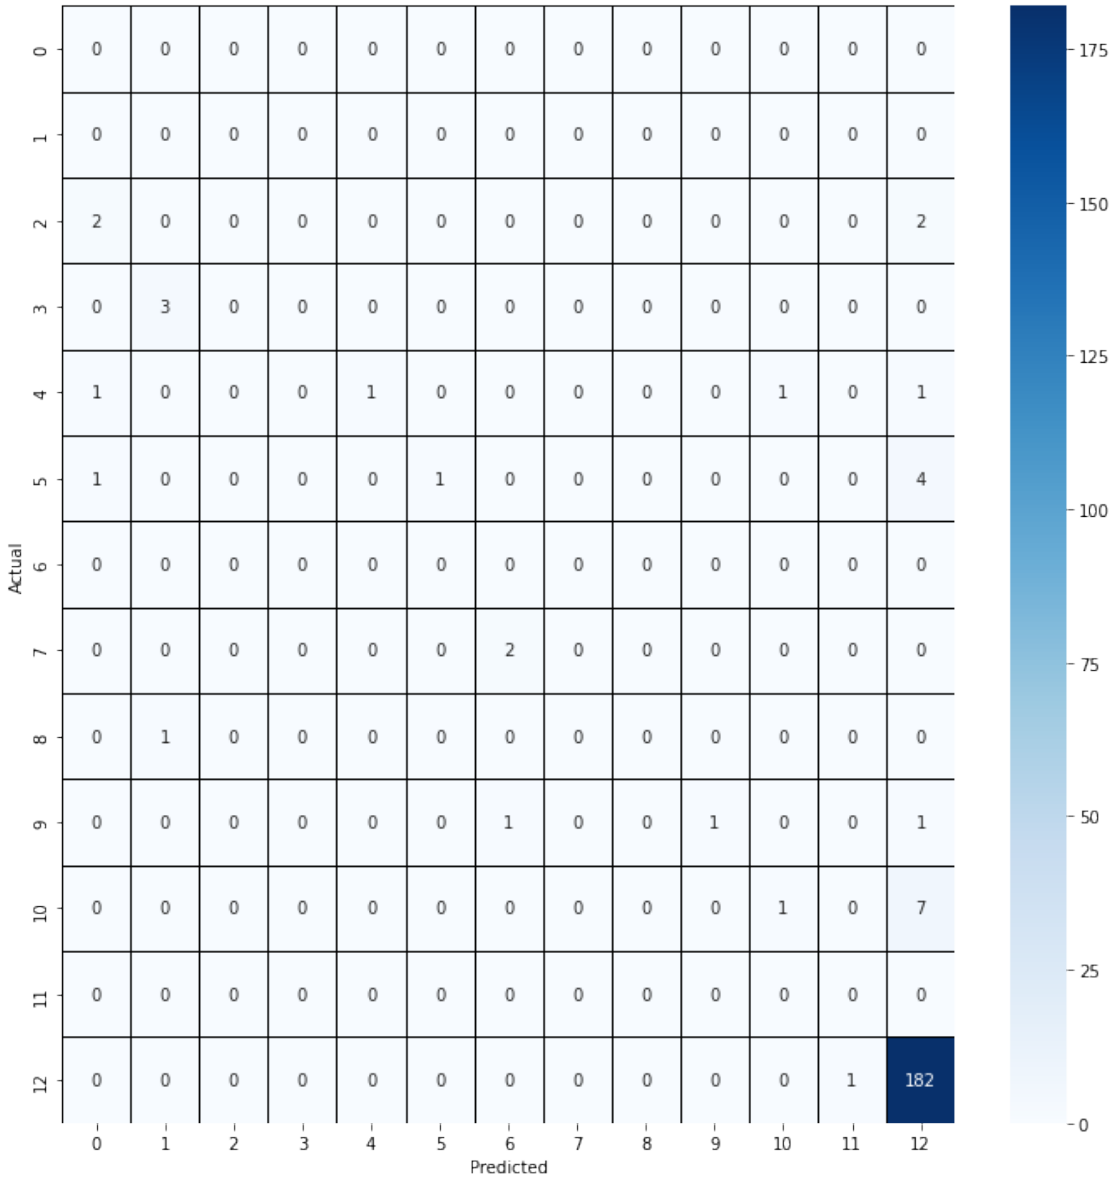
Actual
Predicted
0 0 0 0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0 0 0 0
2 0 0 0 0 0 0 0 0 0 0 0 2
0 3 0 0 0 0 0 0 0 0 0 0 0
1 0 0 0 1 0 0 0 0 0 1 0 1
1 0 0 0 0 1 0 0 0 0 0 0 4
0 0 0 0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 2 0 0 0 0 0 0
0 1 0 0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 1 0 0 1 0 0 1
0 0 0 0 0 0 0 0 0 0 1 0 7
0 0 0 0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0 0 1 182
0 1 2 3 4 5 6 7 8 9 10 11 12
175
150
125
100
75
50
25
0